Escuela de Doctorado
y Estudios de Posgrado
Universidad de La Laguna

Informe de proyecto

Data Analysis

Preprocesamiento, PCA, clasificación y evaluación de modelos sobre el conjunto de datos “wine quality dataset”

Máster Universitario en Ingeniería Industrial

Informática Industrial Avanzada

Author: Jorge Luis Luis

Curso académico: 2025-2026

ÍNDICE

1. Introducción y objetivos 3

2. Preprocesamiento de datos 3

3. Reducción de dimensionalidad usando PCA 4

4. Clasificación: entrenamiento de modelos 5

5. Comparación y conclusiones de los resultados obtenidos 6

5.1. Evaluación cruzada de los modelos 6

5.2. Evaluación del rendimiento sobre el conjunto de prueba 7

1. Introducción y objetivos

El objetivo de este proyecto es analizar y predecir la calidad de diferentes vinos basándose en sus propiedades fisicoquímicas (como el grado de alcohol, la acidez o el azúcar residual). Para ello, se emplea el conjunto de datos *Wine Quality*, obtenido del repositorio oficial de la UCI (University of California, Irvine) mediante la librería *ucirepo*. Con este *dataset*, compuesto por 6.497 muestras, se podrá evaluar la capacidad de dos modelos probabilísticos: el *Análisis Discriminante Lineal* (LDA) y *Naive Bayes*; y de uno no paramétrico basado en árboles de decisión: *Bosque Aleatorio* (Random Forest), para identificar patrones químicos y clasificar automáticamente los vinos con una nota del 3 al 9.

2. Preprocesamiento de datos

Se realizó una inspección inicial de las 6.497 muestras, confirmando la integridad del *dataset* al no presentar valores nulos. El análisis descriptivo permitió validar que las variables son predominantemente numéricas y requieren normalización.

La variable objetivo (calidad del vino, valores entre 3-9) muestra un fuerte desbalanceo, ya que se puede apreciar una alta concentración en las clases 5, 6 y 7, y una presencia mínima en los extremos.

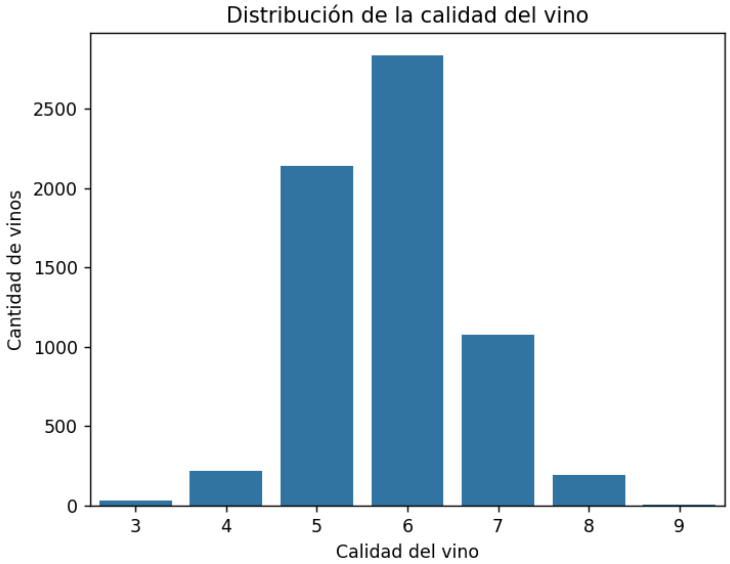


```
-> Cantidad de vinos segun su calidad:
quality
3       30
4      216
5     2138
6     2836
7     1079
8      193
9        5
```

Figura 1:Gráfico de barras que muestra la frecuencia de clases de la variable objetivo y los valores específicos de dicho gráfico

Posteriormente, se calculó la matriz de correlación para identificar redundancias. Se observaron dependencias significativas entre variables como la densidad, el alcohol y los dióxidos de azufre. Esta colinealidad justifica la necesidad de aplicar posteriormente el PCA para optimizar/reducir el espacio de características del *dataset*.

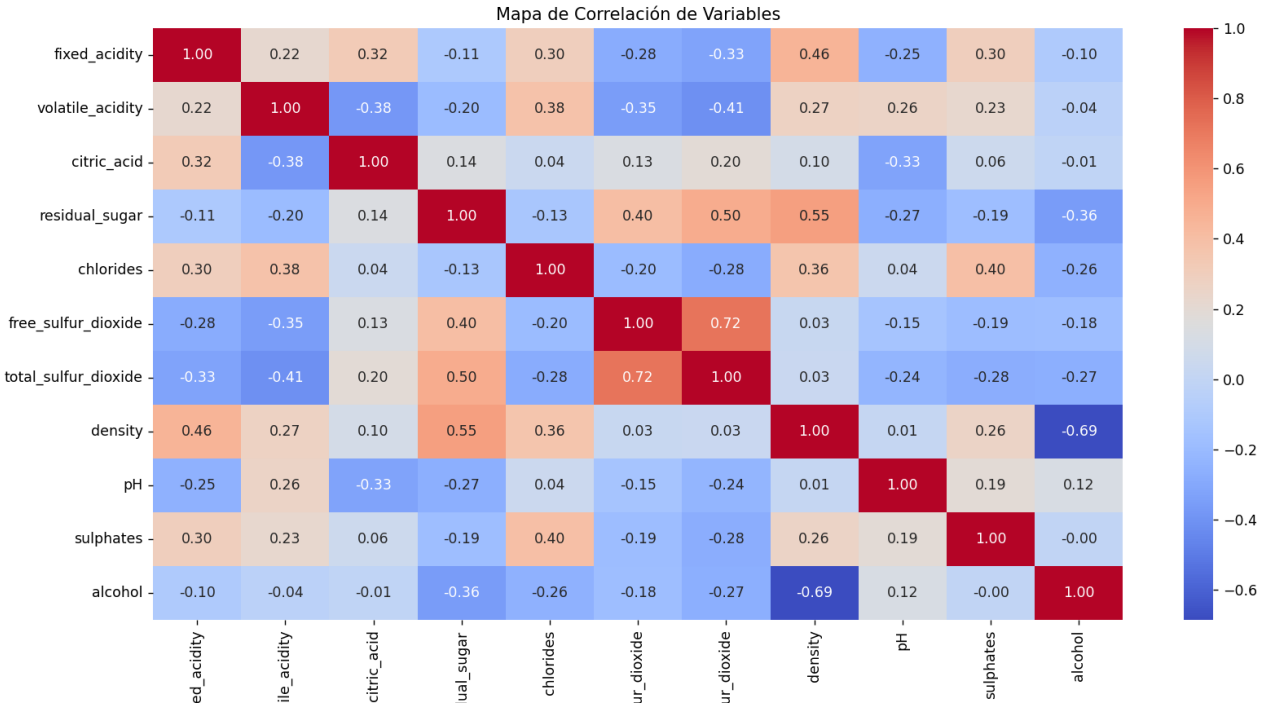

Figura 2: Mapa de calor de correlaciones (Pearson)

Como paso final, se aplicó una estandarización mediante *StandardScaler*. Este procedimiento iguala la escala de las variables, asegurando que las magnitudes de los atributos no sesguen el cálculo de los componentes principales ni el entrenamiento de los clasificadores.

3. Reducción de dimensionalidad usando PCA

Para abordar la correlación identificada entre las características de los vinos y simplificar la estructura del *dataset*, se aplicó un Análisis de Componentes Principales (PCA). El objetivo fue transformar las variables originales en un conjunto de componentes que maximizaran la varianza explicada con la menor pérdida de información posible.

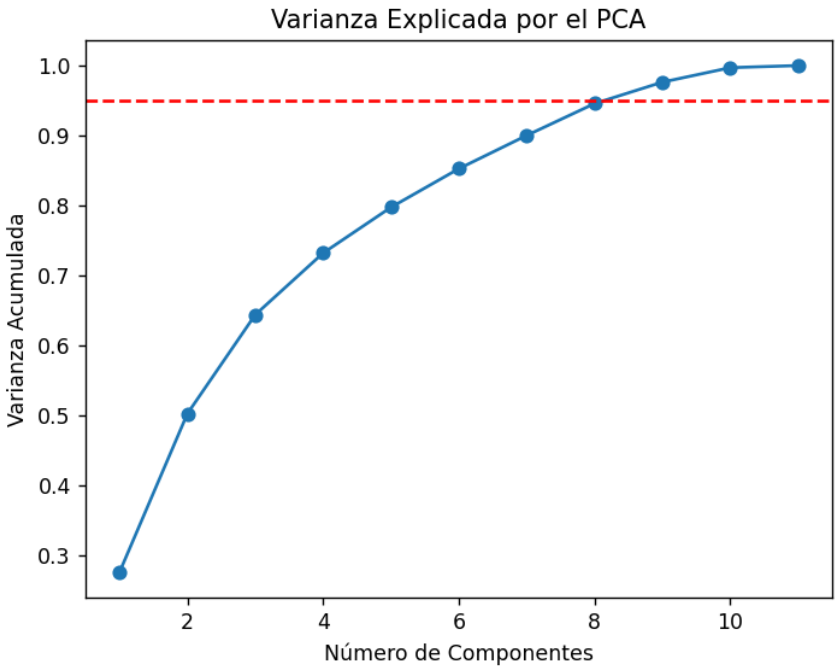

Figura 3: Varianza acumulada frente al número de componentes principales.

Tras evaluar la curva de la varianza acumulada frente al número de componentes, visible en la Figura 3, se determinó que el empleo de 9 componentes principales es el que permite retener más del 95% de la variabilidad total de los datos. Esta reducción no solo optimiza la eficiencia computacional de los algoritmos, sino que también actúa como un filtro de ruido, aislando las dimensiones con mayor capacidad discriminativa para la clasificación.

4. Clasificación: entrenamiento de modelos

Se seleccionaron tres algoritmos predictivos para evaluar y comparar su rendimiento tanto sobre el *dataset* original estandarizado como sobre el espacio reducido por PCA:

- <u>Análisis Discriminante Lineal (LDA):</u>

  Se eligió por ser un modelo muy estable que busca separar las clases de forma lineal. El interés principal era comprobar si este clasificador podía mantener su nivel de acierto utilizando menos variables tras el PCA, o si por el contrario perdía información importante en el camino.

- Naive Bayes (Gaussiano):

  Se empleó para poner a prueba una teoría matemática. Como este modelo asume que todas las variables son independientes entre sí, se quería verificar cuánto mejoraba su rendimiento al pasarle los componentes del PCA, que precisamente crea variables que no tienen relación entre ellas.

- Bosque Aleatorio (Random Forest):

  A diferencia de los otros dos, este modelo no es probabilístico, sino que se basa en árboles de decisión. Aun así, se decidió incluirlo para tener un punto de comparación con los otros dos modelos, ya que es robusto, maneja bien datos complejos y puede servir como referencia de rendimiento.

Para el entrenamiento, los datos se dividieron en un 70% para aprendizaje y un 30% para el test final. Se utilizó una división estratificada (stratify) para intentar que tanto el grupo de entrenamiento como el de test tuvieran la misma proporción de cada calidad. Sin embargo, se vuelve a mencionar que, como hay tan pocas muestras de las calidades extremas (los vinos muy buenos o malos), los modelos tendrán mucha menos información para aprender de esas categorías, lo que dificulta que las identifiquen correctamente.

5. Comparación y conclusiones de los resultados obtenidos

5.1. Evaluación cruzada de los modelos

Para medir el rendimiento de los modelos de forma fiable, se procedió primero a aplicar una validación cruzada con 5 particiones. Este paso permitió ver la precisión media de cada algoritmo comparando cómo funcionan con los datos originales estandarizados frente a los datos transformados por el PCA. Los resultados obtenidos fueron los siguientes:

Tabla 1: Valores de precisión medio de los tres modelos empleados con y sin PCA

Modelo Clasificador	Precisión Media (Sin PCA)	Precisión Media (Con PCA)
1. Análisis Discriminante Lineal (LDA)	49.22%	49.81%
2. Bosque Aleatorio (Random Forest)	48.13%	46.61%
3. Naive Bayes	39.34%	45.93%

Tras analizar estos primeros datos, se llega a ciertas conclusiones con solo fijarse en cómo afecta la transformación de las variables a la precisión de cada algoritmo. Por un lado, el modelo de Bayes, que inicialmente presentaba el peor rendimiento con apenas un 39.34% de acierto, experimentó una mejora al aplicar el PCA, elevando su precisión hasta el 45.93%. Este salto confirma que este modelo sufre cuando las variables originales están muy relacionadas entre sí y se beneficia enormemente de la independencia matemática que le proporcionan los nuevos componentes del PCA.

Por otro lado, el modelo LDA demostró ser el más consistente, manteniendo un rendimiento en torno al 49% tanto con los datos originales como con los procesados, lo que indica que el PCA logró comprimir la información sin perder calidad predictiva pero no consiguió que mejorase la precisión. En contraste, el bosque aleatorio sufrió una leve caída en su rendimiento al utilizar el PCA, bajando de un 48.13% a un 46.61%. Este comportamiento es debido a que el modelo está diseñado para buscar patrones complejos separando variables por su cuenta, simplificarle los datos de forma artificial hace que pierda parte de la información original que sabe aprovechar.

5.2. Evaluación del rendimiento sobre el conjunto de prueba

Tras la primera validación, se evaluaron los modelos empleando la partición de muestras del 30% reservados para esta prueba. Una vez se obtuvo los reportes de cada modelo, se observó diferencias notables en su capacidad predictiva. El bosque aleatorio resultó ser la herramienta más robusta, alcanzando la mayor exactitud global del estudio con un 68%. Su reporte revela que fue el único modelo capaz de identificar, aunque de forma limitada, vinos de las calidades menos frecuentes. Por ejemplo, logró un *recall* del 0.40 para los vinos de calidad 8 y pudo predecir correctamente una pequeña porción de la clase 4, demostrando su superioridad estructural para encontrar patrones complejos en clases con pocas muestras.

```
MODELO 2: BOSQUE ALEATORIO

-> Reporte SIN PCA:

              precision    recall  f1-score   support

           3       0.00      0.00      0.00         9
           4       0.75      0.14      0.23        65
           5       0.72      0.71      0.72       642
           6       0.65      0.76      0.70       851
           7       0.68      0.58      0.62       324
           8       0.96      0.38      0.54        58
           9       0.00      0.00      0.00         1

    accuracy                           0.68      1950
   macro avg       0.54      0.37      0.40      1950
weighted avg       0.69      0.68      0.67      1950
```

```
-> Reporte CON PCA:

              precision    recall  f1-score   support

           3       0.00      0.00      0.00         9
           4       0.82      0.14      0.24        65
           5       0.72      0.70      0.71       642
           6       0.65      0.80      0.72       851
           7       0.70      0.54      0.61       324
           8       1.00      0.40      0.57        58
           9       0.00      0.00      0.00         1

    accuracy                           0.68      1950
   macro avg       0.56      0.37      0.41      1950
weighted avg       0.69      0.68      0.67      1950
```

Figura 4: Reporte de clasificación del modelo Bosque Aleatorio

Por su parte, el análisis discriminante lineal se estancó en un 52% de exactitud global. Aunque se mostró como un modelo muy estable frente a la reducción de dimensionalidad, su reporte de clasificación muestra una incapacidad para detectar las calidades “extremas”, registrando un *recall* de 0.00 para las notas 3, 4, 8 y 9. El modelo ignoró por completo estos extremos, centrando todos sus aciertos de forma segura en las clases centrales.

```
MODELO 1: LDA

-> Reporte SIN PCA:

              precision    recall  f1-score   support

           3       0.14      0.11      0.12         9
           4       0.00      0.00      0.00        65
           5       0.58      0.54      0.56       642
           6       0.50      0.67      0.58       851
           7       0.47      0.30      0.37       324
           8       0.00      0.00      0.00        58
           9       0.00      0.00      0.00         1

    accuracy                           0.52      1950
   macro avg       0.24      0.23      0.23      1950
weighted avg       0.49      0.52      0.50      1950
```

```
-> Reporte CON PCA:

              precision    recall  f1-score   support

           3       0.00      0.00      0.00         9
           4       1.00      0.02      0.03        65
           5       0.57      0.54      0.56       642
           6       0.50      0.67      0.57       851
           7       0.46      0.30      0.36       324
           8       0.00      0.00      0.00        58
           9       0.00      0.00      0.00         1

    accuracy                           0.52      1950
   macro avg       0.36      0.22      0.22      1950
weighted avg       0.52      0.52      0.49      1950
```

Figura 5: Reporte de clasificación del modelo LDA

En cuento al caso del Naive Bayes, este logró subir a un 51% de exactitud operando sobre los componentes del PCA, su reporte detalla que esta mejora se basó casi exclusivamente en un aumento masivo de predicciones correctas para la nota 6 (alcanzando un *recall* del 0.69). Sin embargo, al igual que el LDA, fracasó estrepitosamente en el resto de las categorías extremas, confirmando que la simplificación matemática le ayudó a predecir mejor lo habitual, pero no a predecir lo que no lo es.

```
MODELO 3: NAIVE BAYES

-> Reporte SIN PCA:

              precision    recall  f1-score   support

           3       0.11      0.44      0.17         9
           4       0.22      0.12      0.16        65
           5       0.52      0.46      0.49       642
           6       0.47      0.42      0.44       851
           7       0.32      0.46      0.38       324
           8       0.09      0.12      0.10        58
           9       0.00      0.00      0.00         1

    accuracy                           0.42      1950
   macro avg       0.25      0.29      0.25      1950
weighted avg       0.44      0.42      0.43      1950
```

```
-> Reporte CON PCA:

              precision    recall  f1-score   support

           3       0.10      0.44      0.16         9
           4       0.00      0.00      0.00        65
           5       0.59      0.44      0.50       642
           6       0.49      0.69      0.57       851
           7       0.48      0.35      0.41       324
           8       0.50      0.03      0.06        58
           9       0.00      0.00      0.00         1

    accuracy                           0.51      1950
   macro avg       0.31      0.28      0.24      1950
weighted avg       0.50      0.51      0.49      1950
```

Figura 6: Reporte de clasificación del modelo Naive Bayes

A pesar de estas diferencias en la exactitud y en el reparto de aciertos, al analizar los valores de las matrices de confusión se descubre que los tres modelos tienen un comportamiento conservador. Se puede apreciar que todos tienden a clasificar la mayoría de los vinos dentro de las calidades medias. Este comportamiento es una consecuencia del fuerte desbalanceo de los datos. Al carecer de ejemplos suficientes de vinos excelentes o muy deficientes, los modelos deciden apostar por las categorías más abundantes para minimizar el riesgo de error.

```
-> Matriz de Confusión SIN PCA (LDA):

[[  1   0   3   3   1   1   0]
 [  3   0  35  26   1   0   0]
 [  2   0 347 287   5   1   0]
 [  1   0 199 571  78   0   2]
 [  0   0  15 211  98   0   0]
 [  0   0   0  34  24   0   0]
 [  0   0   0   0   1   0   0]]

-> Matriz de Confusión CON PCA (LDA):

[[  0   0   4   3   1   1   0]
 [  1   1  37  24   2   0   0]
 [  1   0 346 290   4   1   0]
 [  0   0 204 567  79   0   1]
 [  0   0  11 216  97   0   0]
 [  0   0   0  33  25   0   0]
 [  0   0   0   0   1   0   0]]
```

```
-> Matriz de Confusión SIN PCA (Bosque Aleatorio):

[[  0   0   3   6   0   0   0]
 [  0   9  31  23   2   0   0]
 [  0   1 458 179   4   0   0]
 [  0   2 135 651  63   0   0]
 [  0   0   8 128 187   1   0]
 [  0   0   2  16  18  22   0]
 [  0   0   0   0   1   0   0]]

-> Matriz de Confusión CON PCA (Bosque Aleatorio):

[[  0   0   5   3   1   0   0]
 [  0   9  34  22   0   0   0]
 [  0   1 449 186   6   0   0]
 [  0   1 122 680  48   0   0]
 [  0   0   9 141 174   0   0]
 [  0   0   1  14  20  23   0]
 [  0   0   0   0   1   0   0]]
```

```
-> Matriz de Confusión SIN PCA (Naive Bayes):

[[  4   1   3   0   1   0   0]
 [  3   8  23  19  11   1   0]
 [ 16  12 294 269  49   2   0]
 [ 10  13 213 358 229  27   1]
 [  2   2  23 107 149  41   0]
 [  2   0   5  15  29   7   0]
 [  0   0   0   0   1   0   0]]

-> Matriz de Confusión CON PCA (Naive Bayes):

[[  4   0   3   2   0   0   0]
 [  5   0  32  27   1   0   0]
 [ 14   0 281 342   5   0   0]
 [ 15   0 157 586  92   1   0]
 [  1   0   6 203 113   1   0]
 [  1   0   1  33  21   2   0]
 [  0   0   0   0   1   0   0]]
```

Figura 7: Matrices de confusión de los modelos evaluados, evidenciando la concentración de predicciones en las columnas centrales correspondientes a las calidades 5 y 6.

Estos resultados demuestran que, aunque el tipo de modelo empleado juega un papel fundamental en la capacidad predictiva, en este caso concreto la verdadera limitación es la falta de datos para las calidades muy bajas y altas. Para solucionar este problema y lograr que el sistema aprenda a detectar mejor las categorías, se tendría que introducir nuevos registros mediante técnicas como el *data augmentation,* generando ejemplos que mejoren el aprendizaje, o bien obteniendo una mayor cantidad de información real de nuevas fuentes.